

Perbandingan Algoritma Support Vector Machine (SVM) dan Naive Bayes pada Analisis Sentimen Bahasa Jawa dan Sunda

Galuh Kusuma Putri^{a1}, Herry Sujaini^{a2}, Desepta Isna Ulumi^{a3}

^aJurusan Informatika Universitas Tanjungpura

Jl. Prof. Dr. H. Hadari Nawawi, Pontianak, Kalimantan Barat 78115

¹galuhkusumaputri04@gmail.com

²hs@untan.ac.id

³ulum@informatika.untan.ac.id

Abstrak

Perbedaan struktur kalimat, pilihan kata, dan tingkat kesopanan dalam Bahasa Jawa dan Sunda dibandingkan dengan Bahasa Indonesia membuat analisis sentimen menjadi lebih kompleks. Karakteristik unik kedua bahasa ini sering kali sulit dipahami, terutama bagi bukan penutur aslinya, sehingga metode pemrosesan teks yang umum digunakan untuk Bahasa Indonesia tidak selalu efektif. Oleh karena itu, diperlukan pendekatan yang dapat mengklasifikasikan sentimen teks berbahasa daerah ini, apakah bersifat positif, negatif, atau netral, guna meningkatkan pemahaman terhadap opini masyarakat serta memperluas aksesibilitas informasi. Mengingat tantangan tersebut, penelitian ini berfokus pada eksplorasi metode klasifikasi yang dapat secara efektif menangani karakteristik unik dari Bahasa Jawa dan Sunda dalam analisis sentimen. Untuk itu, penelitian ini bertujuan melakukan perbandingan antara algoritma *Support Vector Machine* (SVM) dan *Naive Bayes* guna menentukan pendekatan yang paling sesuai dalam mengklasifikasikan sentimen teks pada kedua bahasa ini. SVM mencari garis pemisah terbaik untuk mengklasifikasikan data, sedangkan Naive Bayes menggunakan perhitungan probabilitas berdasarkan pola kata yang muncul. Dalam penelitian ini ekstraksi fitur dilakukan menggunakan TF-IDF dan seleksi fitur menggunakan *Chi-Square*. Data yang digunakan dari Indonesian NLP data catalogue yang terdapat mulai dari tahun 2020-2023. Hasil penelitian menunjukkan bahwa metode klasifikasi *Support Vector Machine* (SVM) lebih baik dari pada *Naive Bayes* di kedua bahasa. SVM mendapatkan akurasi pada Bahasa Jawa sebesar 76% dan Bahasa Sunda sebesar 80% sedangkan *Naive Bayes* pada Bahasa Jawa sebesar 73% dan Bahasa Sunda sebesar 77%. SVM menjadi metode terbaik dalam penelitian ini karena menunjukkan performa yang lebih baik pada kedua bahasa dibandingkan *Naive Bayes*.

Kata kunci: Analisis Sentimen, *Support Vector Machine*, *Naive Bayes*, TF-IDF, *Chi-Square*

Comparison of Support Vector Machine (SVM) and Naive Bayes Algorithms on Sentiment Analysis of Javanese and Sundanese Languages

Abstract

Differences in sentence structure, word choice, and politeness levels in Javanese and Sundanese compared to Indonesian make sentiment analysis more complex. The unique characteristics of these two languages are often difficult for non-native speakers to understand, so commonly used text processing methods for Indonesian are not always effective. Therefore, there is a need for an approach that can classify the sentiment of these regional language texts, whether they are positive, negative or neutral, in order to improve the understanding of public opinion and expand the accessibility of information. Given these challenges, this research focuses on exploring classification methods that can effectively handle the unique characteristics of Javanese and Sundanese in sentiment analysis. To this end, this research aims to conduct a comparison between Support Vector Machine (SVM) and Naive Bayes algorithms to determine the most suitable approach in classifying text sentiment in these two languages. SVM looks for the best dividing line to classify the data, while Naive Bayes uses probability calculations based on word patterns that appear. In this research, feature extraction is done using TF-IDF and feature selection using Chi-Square. The data used is obtained from the Indonesian NLP data catalogue recorded from 2020-2023. The results showed that the Support Vector Machine (SVM) classification method was better than Naive Bayes in both languages. SVM obtained accuracy in Javanese at 76% and Sundanese at 80% while Naive Bayes in Javanese at 73% and Sundanese at 77%. SVM is the best method in this study because it shows better performance in both languages than Naive Bayes..

Keywords: Sentiment Analysis, Support Vector Machine, Naive Bayes, TF-IDF, Chi-Square

I. PENDAHULUAN

Dalam era digital saat ini, penggunaan media sosial di Indonesia mengalami perkembangan yang sangat pesat. Di tengah ragam bahasa daerah yang ada di Indonesia, Bahasa Jawa (BJ) dan Bahasa Sunda (BS) menonjol sebagai alat komunikasi utama bagi banyak masyarakat. Kedua bahasa ini digunakan untuk berbagi opini dan mengekspresikan perasaan di berbagai platform digital. Fenomena ini menciptakan peluang yang luas untuk mempelajari pandangan masyarakat terhadap berbagai topik, ulasan produk, dan isu-isu terkini.

Namun, tantangan muncul karena perbedaan karakteristik bahasa antara Bahasa Jawa dan Sunda dengan Bahasa Indonesia, yang menjadikan kedua bahasa ini sulit dipahami oleh masyarakat umum yang bukan penutur aslinya. Dalam penelitian yang dilakukan oleh Alden Delfian Wattimena (2018), menunjukkan bahwa keberagaman bahasa, termasuk bahasa daerah, menjadi tantangan signifikan dalam analisis sentimen teks di media sosial. Penelitian ini mengidentifikasi tantangan yang muncul akibat keberagaman bahasa yang digunakan oleh masyarakat Indonesia. Perbedaan dalam struktur kalimat, pilihan kata, serta penggunaan bentuk-bentuk halus atau kasar dalam bahasa daerah menyulitkan proses klasifikasi teks atau opini yang berada di media sosial [1]. Dalam Bahasa Jawa dan Sunda, terdapat variasi dalam tingkat kesopanan dan kosakata yang tidak selalu dipahami oleh bukan penutur aslinya. Oleh karena itu, diperlukan pendekatan yang dapat membantu mengenalkan kedua bahasa ini ke masyarakat yang lebih luas serta meningkatkan pemahaman terhadap opini yang disampaikan dalam teks berbahasa daerah. Salah satu pendekatan yang relevan adalah analisis sentimen, yang dapat membantu mengklasifikasikan teks ke dalam sentimen positif, netral, atau negatif berdasarkan sikap dan emosi yang terkandung dalam teks [2].

Analisis sentimen merupakan bagian dari *Natural Language Processing* (NLP) yang digunakan untuk mengekstraksi, menggali, dan mengolah data teks dengan tujuan mengidentifikasi apakah opini yang terkandung dalam teks tersebut bersifat positif, negatif atau netral [3]. Dalam melakukan analisis sentimen pada teks dalam Bahasa Jawa dan Sunda, diperlukan pendekatan algoritma yang efektif untuk menghasilkan hasil yang akurat dan bermakna. Dari banyaknya penelitian terdahulu, sudah banyak yang melakukan penelitian mengenai klasifikasi sentimen pada berbagai bahasa. Dalam *text mining*, algoritma klasifikasi seperti *Naive Bayes* dan *Support Vector Machine* sering digunakan untuk menentukan kategori atau label yang tepat untuk setiap dokumen.


Seperti penelitian yang dilakukan oleh Nugroho, dkk (2021), mengenai SVM dengan kernel linear menghasilkan akurasi yang lebih baik dalam klasifikasi sentimen Pemilihan Presiden Amerika 2020, dengan perbedaan akurasi sebesar 12% [4]. Penelitian lainnya oleh Firdausi, dkk (2022) juga menunjukkan keunggulan SVM dalam analisis sentimen terhadap pembelajaran daring selama pandemi COVID-19 di Indonesia, dengan akurasi mencapai 72% [5]. Ini membuktikan bahwa SVM lebih unggul dalam menangani berbagai jenis data yang

kompleks dibandingkan *Naive Bayes*. Di sisi lain, penelitian oleh Permana, dkk (2023) menunjukkan bahwa *Naive Bayes* merupakan algoritma yang lebih sederhana dan cepat, serta memiliki kemampuan untuk menghasilkan performa yang baik pada dataset yang lebih seimbang [6]. Dengan optimasi fitur seperti TF-IDF dan *Chi-Square*, *Naive Bayes* bahkan dapat mencapai akurasi yang tinggi, yaitu 91.6%.

Berdasarkan penelitian-penelitian sebelumnya, setiap algoritma memiliki keunggulan tersendiri dalam hal kecepatan dan akurasi. Algoritma *Support Vector Machine* (SVM) sangat baik untuk menangani data berukuran besar dan memberikan hasil yang konsisten. Sebaliknya, *Naive Bayes* (NB) adalah algoritma yang lebih sederhana namun memiliki keunggulan dalam kecepatan proses. Dari kelebihan masing-masing algoritma inilah, ingin dilihat algoritma mana yang menghasilkan performa yang lebih baik dan dievaluasi algoritma mana yang lebih tepat diterapkan pada teks berbahasa Jawa dan Sunda, yang memiliki struktur dan kosakata yang berbeda dengan Bahasa Indonesia. Sehingga akan dilakukan penelitian membandingkan kinerja kedua algoritma yaitu *Support Vector Machine* (SVM) dan *Naive Bayes*, dalam menganalisis teks dalam Bahasa Jawa dan Sunda. Dengan perbandingan ini, diharapkan akan ditemukan algoritma yang paling sesuai untuk menganalisis sentimen dalam Bahasa Jawa dan Sunda serta dapat membantu memahami perasaan dan opini dari teks bahasa-bahasa tersebut.

II. METODOLOGI

Pada bagian metodologi, akan dipaparkan gambaran proses yang dilakukan dalam mencapai tujuan yang ada pada penelitian ini. Gambaran proses yang dilakukan dapat dilihat pada gambar 1.



Gambar 1. Diagram Alur Penelitian

A. Pengumpulan Data

Data dikumpulkan untuk mendapatkan informasi yang berkaitan dengan penelitian yang akan dilakukan [7]. Data yang dikumpulkan merupakan data teks Bahasa Jawa Ngoko dan Bahasa Sunda dengan total masing-masing bahasa yaitu 5000 data, dari data pada situs Indonesian NLP data catalogue yaitu <https://indonlp.github.io/nusa-catalogue/index.html>. Dataset utama yang digunakan dalam penelitian ini adalah NusaX, yaitu korpus teks paralel untuk berbagai bahasa daerah di Indonesia, termasuk Bahasa Jawa Ngoko dan Bahasa Sunda yang dikembangkan oleh Winata et al. (2023). Kalimat yang dipilih memiliki makna sentimen yang jelas, baik itu positif, negatif, atau netral. Data yang dikumpulkan berbentuk excel dan disimpan kedalam file dengan format csv.

B. Pelabelan

Proses pemberian label pada data diperlukan agar algoritma *Naive Bayes* dan *Support Vector Machine* bisa memahami dataset. Dalam penelitian ini, sentimen dibagi menjadi tiga kategori utama yaitu sentimen positif, negatif dan netral. Untuk menentukan kelasnya, proses pelabelan dilakukan secara manual oleh dua penutur asli Bahasa Jawa dan Sunda. Ini dilakukan untuk meningkatkan akurasi anotasi atau proses pemberian label. Jika terjadi perbedaan label antar pemberi label, maka dilakukan diskusi untuk menentukan label akhir agar meminimalkan bias dan memastikan konsistensi dalam anotasi.

C. Preprocessing Data

Pre-processing atau tahap persiapan adalah proses mengubah data agar sesuai dengan format yang diharapkan dan dapat diproses [8]. *Pre-processing* juga mencakup metode untuk menangani *data noisy*, yaitu teks yang mengandung karakter atau elemen tidak relevan yang dapat mengganggu analisis. Tahapan *pre-processing* yang dilakukan pada penelitian ini terdapat 3 proses, yaitu:

- 1) *Cleansing Data*: ini adalah tahapan pembersihan karakter *non-alfabetis* untuk meminimalkan gangguan. *Username*, *hashtag*, URL teks, angka, tanda baca, emotikon, spasi kosong, karakter tunggal, simbol, dan karakter tidak lazim adalah semua karakter yang dihapus [9].
- 2) *Case Folding*: digunakan untuk merubah seluruh huruf kapital menjadi huruf kecil atau *lower case*. Hal ini dilakukan tanpa terkecuali pada awal kalimat, penamaan orang, kota dll [10].
- 3) *Tokenisasi*: proses ini memecah kalimat menjadi kata-kata individu, yang kemudian dikenal sebagai token [9]. Pada proses ini dokumen akan dipecah menjadi per kata, yang artinya memisah kan satu kata dengan kata lain.

D. Ekstraksi Fitur

Ekstraksi fitur adalah proses mengubah data yang sudah diproses menjadi data yang memiliki fitur. Metode TF-IDF digunakan untuk ekstraksi fitur dalam penelitian ini. *Frequency-Inverse Document Frequency* (TF-IDF) adalah algoritma yang memiliki kemampuan untuk

membobotan kata. Dataset yang masih berbentuk tulisan, sebelum melewati pemrosesan harus diekstrak terlebih dahulu dengan TF-IDF. Tujuannya adalah untuk menampilkan tulisan dalam bentuk angka sebelum diproses oleh *Naive Bayes* dan *Support Vector Machine*. [8]. Alasan penggunaan TF-IDF yaitu untuk menghilangkan kata yang kurang bermakna. Kata-kata umum yang sering muncul tetapi tidak memiliki nilai informatif tinggi akan memiliki bobot yang lebih rendah. Sedangkan kata-kata yang jarang muncul tetapi memiliki arti signifikan akan mendapatkan bobot lebih tinggi, sehingga lebih berpengaruh dalam klasifikasi.

Proses pemberian bobot pada kata dengan TF-IDF terdiri dari proses menghitung *Term Frequency* (TF) yaitu jumlah kata yang sering muncul dalam dokumen dan *Inverse Document Frequency* (IDF) yaitu menghitung logaritma dari pembagian jumlah dokumen dengan frekuensi kemunculan kata tersebut. Perhitungan TF-IDF diperoleh dengan mengalikan nilai TF dengan nilai IDF. Menurut penelitian terdahulu yang dilakukan oleh Tuhuteru dan Iriani, (2018) pembobotan *term* dengan TF-IDF dihitung berdasarkan persamaan 1.

$$TF \times IDF_{t,d} = TF_{t,d} \times IDF_t \quad (1)$$

$TF_{t,d}$ merupakan *term frequency*, yaitu frekuensi kemunculan sebuah *term*/token dalam dokumen tertentu. Sementara itu, IDF_t adalah *inverse document frequency*, yang dihitung sebagai logaritma basis 10 dari rasio jumlah total dokumen N terhadap DF_t . Dengan demikian, nilai TF dan IDF dapat ditentukan melalui persamaan 2 dan 3.

$$TF_{t,d} = \frac{f_{t,d}}{n_d} \quad (2)$$

$$IDF_t = \log \frac{N}{DF_t} \quad (3)$$

E. Seleksi Fitur

Chi-Square merupakan salah satu metode seleksi fitur supervised yang mampu menghilangkan fitur tanpa mengurangi tingkat akurasi yang dihasilkan [11]. *Chi-Square* digunakan dalam proses seleksi fitur karena dapat mengurangi fitur yang kurang relevan dalam klasifikasi, dengan menggunakan teori statistik untuk menguji apakah suatu term independen terhadap kategorinya. *Chi-Square* juga dapat memilih fitur yang memiliki hubungan kuat dengan kategori sentimen sehingga dapat meningkatkan performa klasifikasi.

Setelah diketahui nilai *Chi-Square* nya, kata-kata diurutkan dari nilai *Chi-Square* tertinggi ke terendah. Semakin tinggi nilai *Chi-Square*, semakin bergantung sebuah fitur, yang menunjukkan pentingnya fitur tersebut dalam proses klasifikasi [12].

Menurut penelitian terdahulu yang dilakukan oleh Chairunnisa, dkk (2022), berikut merupakan persamaan rumus untuk mendapatkan uji *Chi-Square* dapat dilihat pada persamaan 4.

$$\chi^2 = \sum \frac{(O_i - E_i)^2}{E_i} \quad (4)$$

F. Proses Klasifikasi

Model klasifikasi dilatih dengan menggunakan data yang telah dilabeli. Dalam penelitian ini, data dibagi

menggunakan metode *splitting* dengan perbandingan 80% untuk data pelatihan (*training*) dan 20% untuk data pengujian (*testing*), bertujuan memastikan model mampu menggeneralisasi data yang belum pernah dilihat sebelumnya [13]. Model algoritma yang digunakan yaitu *Naive Bayes* dan *Support Vector Machine* (SVM). Setelah model dilatih, hasilnya disimpan dan digunakan untuk memprediksi label sentimen pada data uji.

1) *Naive Bayes*

Naive Bayes adalah salah satu algoritma *machine learning* yang menggunakan prinsip probabilitas dan statistik yang diperkenalkan oleh ilmuwan asal Inggris, Thomas Bayes. Algoritma ini bekerja dengan memperkirakan probabilitas kejadian di masa depan berdasarkan data dari masa lalu [14]. *Naive Bayes* memiliki asumsi yang sangat kuat (naif) bahwa algoritma ini independen dari berbagai kondisi. Salah satu kelebihan utama *Naive Bayes* adalah kemampuannya untuk menyesuaikan proses klasifikasi data sesuai dengan sifat dan kebutuhan spesifik [7]. Berdasarkan persebaran datanya dapat dibedakan menjadi tiga jenis, yaitu *bernoulli naive bayes*, *gaussian naive bayes*, dan *multinomial naive bayes* [15]. Menurut penelitian terdahulu yang dilakukan oleh Darwis, dkk (2021), dasar dari *Naive Bayes* yang dipakai dalam pemrograman adalah rumus *Bayes* seperti pada persamaan 5.

$$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)} \quad (5)$$

Untuk mengklasifikasikan teks atau dokumen, metode *multinomial Naive Bayes*, yang mengevaluasi tidak hanya kata yang muncul tetapi juga jumlah kata yang muncul, adalah yang paling cocok.

Pada persamaan 6 merupakan persamaan model penyederhanaan dari Metoda *Bayes*.

$$V_{MAP} = \arg \max_{V_j \in V} P(V_j | a_1, a_2, \dots, a_n) \quad (6)$$

Berdasarkan persamaan 6, maka persamaan 5 dapat ditulis seperti yang terdapat pada persamaan 7.

$$V_{MAP} = \arg \max_{V_j \in V} \frac{P(a_1, a_2, \dots, a_n | V_j) \times P(V_j)}{P(a_1, a_2, \dots, a_n)} \quad (7)$$

Dengan asumsi independensi fitur, persamaan 7 dapat ditulis seperti yang terdapat pada persamaan 8.

$$P(a_1, a_2, \dots, a_n | V_j) = P(a_1 | V_j) \times P(a_2 | V_j) \times \dots \times P(a_n | V_j) \quad (8)$$

Jadi, persamaan akhir dapat dilihat pada persamaan 9.

$$V_{MAP} = \arg \max_{V_j \in V} P(V_j) \times \prod_{i=1}^n P(a_i | V_j) \quad (9)$$

Proses klasifikasi *Naive Bayes* menggunakan fungsi MultinomialNB dalam library *Scikit-learn*. MultinomialNB digunakan karena jenis dari klasifikasi *Naive Bayes* ini mampu mengolah data berupa teks.

2) *Support Vector Machine* (SVM)

Support Vector Machine merupakan metode pembelajaran *supervised* yang memiliki kualitas dan akurasi tinggi. SVM bekerja dengan cara membentuk sebuah garis yang dikenal sebagai *hyperplane* atau garis pemisah yang akan memisahkan setiap kelas opini positif dan opini negatif secara linear dengan pemetaan nonlinier ke dimensi yang cukup tinggi. Waktu proses SVM umumnya lambat tetapi metode ini sangat akurat karena dapat menangani model *nonlinear* yang kompleks

[16]. SVM mengukur kompleksitas hipotesis berdasarkan margin pemisah bidang, tidak bergantung pada jumlah fitur, sehingga dapat menangani data dengan fitur yang banyak. Margin adalah jarak antara titik vektor dalam sebuah kelas dengan *hyperplane*. Kemudian, SVM menemukan perpindahan margin terbaik untuk memisahkan kelas [4].

Persamaan SVM dapat dituliskan sebagai berikut:

- Untuk class 1 ($y_i = -1$): $x_i \times w + b \leq -1$ (10)

- Untuk class 2 ($y_i = +1$): $x_i \times w + b \geq +1$ (11)

SVM sangat bergantung pada parameter yang digunakan, seperti nilai C, nilai epsilon, dan fungsi kernel yang digunakan, untuk proses pencarian *hyperplane* yang optimal [3]. SVM memiliki beberapa jenis kernel, berikut jenis kernelnya ditunjukkan pada tabel 1.

TABEL I
KLASIFIKASI DAN FUNGSI KERNEL SVM

Jenis Kernel	Fungsi
Linear	$K(x_i, x_j) = \text{sum}(x_i, x_j)$
Radial Basis Function	$K(x, y) = \exp\left(-\frac{\ x - y\ ^2}{2\sigma^2}\right)$
Polynomial	$(x_i, x_j + 1)^d$

Proses klasifikasi SVM menggunakan *GridSearch* untuk menemukan kombinasi parameter terbaik yang akan digunakan untuk pelatihan dan pengujian. Proses ini akan membandingkan dua kernel yang ada yaitu linear dan rbf. Untuk uji parameter yang akan digunakan adalah parameter cost (C) dan parameter gamma (γ). Hasilnya merupakan nilai skor terbaik atau *grid score* sebagai penentu parameter terbaik yang akan digunakan untuk melakukan klasifikasi.

G. Evaluasi

Nilai keberhasilan sistem yang dibangun diukur melalui evaluasi. Evaluasi dilakukan untuk menentukan nilai uji dari model yang berhasil diuji, dengan menghitung satu ukuran tertentu terhadap himpunan data uji, yaitu data yang tidak digunakan dalam proses pembuatan model *classification* tersebut. Dari hasil pengujian model menghasilkan *confusion matrix*.

Confusion matrix digunakan untuk mengevaluasi performa suatu model pada tahap evaluasi. *Confusion matrix* berisi informasi asli dan yang diprediksi atau bisa disebut metode untuk mengevaluasi model klasifikasi untuk menentukan keakuratan objek [16]. Pada tabel 2 berikut menunjukkan matriks konfusi tiga kelas.

TABEL II
CONFUSION MATRIX 3 KELAS

		Predicted Class		
		Positive	Neutral	Negative
True Class	Positive	True Positive (TP)	False Neutral (FNt)	False Negative (FN)
	Negative	False Positive (FP)	True Neutral (TNt)	False Negative (FN)
	Neutral	False Positive (FP)	False Neutral (FNt)	True Negative (TN)

Dari matriks tersebut dapat diketahui *accuracy*, *precision*, *recall* dan *f1-score*. Perhitungan *accuracy* dilakukan untuk mengetahui berapa banyak data yang benar yang diklasifikasikan sistem. Perhitungan *precision* dilakukan dengan membandingkan jumlah kelas positif yang diprediksi benar dengan jumlah semua kelas positif. Perhitungan *recall* dilakukan untuk mengetahui perbandingan jumlah kelas positif yang diprediksi benar dibandingkan dengan kelas yang benar positif. Perhitungan *f1-score* diperoleh dari *precision* dan *recall* [4].

Menurut penelitian terdahulu yang dilakukan oleh Nisa, dkk (2019), adapun rumus perhitungannya sebagai berikut:

$$\text{Presisi} = \frac{\text{Jumlah data dengan prediksi benar}}{\text{Jumlah data yang diprediksi}}$$

(12)

$$\text{Recall} = \frac{\text{Jumlah data dengan prediksi benar}}{\text{Jumlah data sebenarnya}}$$

(13)

$$f1 \text{ score} = \frac{2 \times \text{presisi} \times \text{recall}}{\text{presisi} + \text{recall}}$$

(14)

III. HASIL DAN PEMBAHASAN

A. Pengambilan Data

Data yang diambil dari korpus NusaX hanya berbahasa Jawa Ngoko dan Sunda, dengan masing-masing bahasa sebanyak 5000 data. Data yang terpilih mencakup rentang waktu 2020 hingga 2023, yang sudah disimpan dalam format csv. Hasil dari pengambilan data dapat dilihat pada tabel 3 dan tabel 4.

TABEL III
DATA BAHASA JAWA


id	text	sentiment
0	Cepak saka hotelku nginep, namung digawa mlaku...	positive
1	Kangkunge lumayan nanging yuyu saus padange ng...	negative
2	Iya bener, deknen lagi jaga warung.	neutral
3	Manggon nang braga city walk sing sak gedung k...	positive
...	...	...
4996	Nek bojo lagi lara, rewel, utawa jeleh...weneh...	positive
4997	Dadi, dakkira laporan2 sing ditulis karo instu...	negative
4998	Dikandhani apik-apik nyepelekn, diseneni mala...	negative
4999	Seneng lah... dijak dolan nag Mall ... kon jaj...	positive

TABEL IV
DATA BAHASA SUNDA

id	text	sentiment
0	Geus ngalewat sasak di balikeun deui motor teh...	negative
1	Sing sabar neng...da moal lecet saukur ngantos...	positive
2	Bener,apalagi dijalar cinunuk udah jalan sempi...	negative
3	KEHED SIA ANYING TEBISA CICING PISAN SIA ANYIN...	negative
...	...	...
4996	Naha urang mah watir bisi rumah tangga maneh a...	negative
4997	pasca tornado , menlu ri ingatkan wni di oklah...	neutral
4998	aya hubungan naon luthfi sarta darin ? ieu san...	neutral
4999	PPP tacan nangtukeun saha calon presiden anu d...	neutral

B. Pelabelan

Dataset yang sudah terkumpul, dilabelkan secara manual. Proses validasi dilakukan dengan *cross-checking* antar-anotator untuk mengurangi kesalahan labeling. Dari 5000 data yang dikumpulkan, pada Bahasa Jawa dihasilkan sebanyak 2016 data ulasan negatif, 872 data ulasan netral dan 2112 data ulasan positif, sedangkan pada Bahasa Sunda dihasilkan sebanyak 2797 data ulasan negatif, 626 data ulasan netral dan 1577 data ulasan positif. Banyaknya jumlah data dalam Bahasa Jawa dan Bahasa Sunda ditunjukkan pada gambar 2.



Gambar 2. Perbandingan Jumlah Sentimen

C. Pre-processing Data

Tahapan *pre-processing* data perlu dilakukan untuk membuat pemrosesan dataset yang tidak terstruktur menjadi lebih terstruktur dan membuat pemrosesan analisis sentimen lebih mudah. Tahapan *pre-processing data* yang sudah dilakukan yaitu *cleansing data*, *case folding* dan tokenisasi. Beberapa hasil dari penerapan *pre-processing data* Bahasa Jawa dan Bahasa Sunda dapat dilihat pada tabel 5.

TABEL V
HASIL PRE-PROCESSING DATA

	text	sentiment	cleaned text	casefolded text	tokens
Bahasa Jawa	Cepak saka hotelku nginep, namung digawa...	positive	Cepak saka hotelku nginep namung digawa...	cepak saka hotelku nginep namung digawa...	[cepak, saka, hotelku, nginep, namung, digawa...]
	Kangkunge lumayan nanging yuyu saus...	negative	Kangkunge lumayan nanging yuyu saus...	kangkunge lumayan nanging yuyu saus...	[kangkunge, lumayan, nanging, yuyu, saus,...]
	Iya bener, deknen lagi jaga warung.	neutral	Iya bener deknen lagi jaga warung	iya bener deknen lagi jaga warung	[iya, bener, deknen, lagi, jaga, warung]

	text	sentiment	cleaned text	casefolded text	tokens
Bahasa Sunda	Sing sabar neng...da moal lecet saukur...	positive	Sing sabar neng da moal lecet saukur...	sing sabar neng da moal lecet saukur...	[sing, sabar, neng, da, moal, lecet, saukur...]
	KEHED SIA ANYING TEBISA CICING PISAN SIA...	negative	KEHED SIA ANYING TEBISA CICING PISAN SIA...	kehed sia anying tebisa cicing pisan sia...	[kehed, sia, anying, tebisa, cicing, pisan, sia...]
	diuk dina jojodog sambil moyan,teu ...	neutral	diuk dina jojodog sambil moyan teu...	diuk dina jojodog sambil moyan teu...	[diuk, dina, jojodog, sambil, moyan, teu...]

D. Feature Engineering

Pada langkah *feature engineering*, pembobotan kata diterapkan dengan menggunakan TF-IDF, dan seleksi fitur dilakukan melalui metode *Chi-Square*. *Feature engineering* menampilkan kolom fitur dan target yang sudah dipisahkan. Variabel X menampilkan 'clean_teks' yaitu data yang telah dilakukan pre-processing data sebelumnya dan variabel y menampilkan 'sentiment', yaitu sentimen berupa numerik yang memiliki keterangan 1 adalah sentimen netral, 0 adalah sentimen negatif, dan 2 adalah sentimen positif.

1) Ekstraksi Fitur (TF-IDF)

Pada proses pembobotan berdasarkan fitur TF-IDF, jumlah fitur atau kata unik yang dihasilkan dari 5000 data yang telah dilakukan pembersihan data untuk Bahasa Jawa menghasilkan 14340 kata unik dan untuk Bahasa Sunda menghasilkan 15099 kata unik yang siap digunakan untuk pemodelan. TF-IDF menggambarkan pentingnya kata dalam dokumen. Kata menjadi semakin penting dalam dokumen jika nilai TF-IDF-nya semakin tinggi. Tabel 6 menunjukkan ranking skor TF-IDF pada Bahasa Jawa dengan 10 nilai pembobotan tertinggi dari 14340 fitur yang dihasilkan. Kata "sing" memiliki skor TF-IDF tertinggi (0.020533791).

TABEL VI
RANKING SKOR TF-IDF PADA BAHASA JAWA

Ranking	Kata	Hasil TF-IDF
1	sing	0.020533791
2	aku	0.019121487
3	ora	0.017679477
4	iku	0.016961074
5	lan	0.01627729
6	wong	0.015154595
7	iki	0.014514345
8	kui	0.014446024
9	karo	0.013600155
10	dhewe	0.013458888

Tabel 7 menunjukkan ranking skor TF-IDF pada Bahasa Sunda dengan 10 nilai pembobotan tertinggi dari

15099 fitur yang dihasilkan. Kata "urang" memiliki skor TF-IDF tertinggi (0.017660541).

TABEL VII
RANKING SKOR TF-IDF PADA BAHASA SUNDA

Ranking	Kata	Hasil TF-IDF
1	urang	0.017660541
2	nu	0.017450141
3	teu	0.017235611
4	di	0.015735928
5	pisan	0.014935584
6	jeung	0.01449254
7	abdi	0.01429518
8	aing	0.014294006
9	teh	0.014201016
10	ka	0.014077184

2) Seleksi Fitur (*Chi-Square*)

Dalam penelitian ini, seleksi fitur dilakukan menggunakan metode *Chi-Square* dengan nilai SelectKBest (chi2, k=1500) yang artinya memilih 1500 fitur dengan nilai *Chi-Square* tertinggi dari jumlah fitur yang dihasilkan pada ekstraksi fitur dengan TF-IDF. Semakin tinggi nilai *Chi-Square* maka semakin baik fiturnya.

Berikut beberapa hasil fitur-fitur yang sudah diseleksi dengan *Chi-Square* tertinggi pada Bahasa Jawa ditunjukkan pada tabel 8. Kata "kurang" memiliki nilai *Chi-Square* tertinggi yaitu 27.40726138, menunjukkan bahwa kata ini sangat relevan dalam membedakan kelas dalam dataset.

TABEL VIII
SELEKSI FITUR TERBAIK BAHASA JAWA

Ranking	Kata	Nilai Chi-Square
1	kurang	27.40726138
2	apik	19.08241521
3	seneng	17.92448947
4	bisa	17.12937099
5	ora	15.56015903
...	...	...
1496	testimoni	1.524192033
1497	siale	1.522902823
1498	dilakoke	1.522337356
1499	rame	1.521996471
1500	kesenian	1.521700904

Berikut beberapa hasil fitur-fitur yang sudah diseleksi dengan *Chi-Square* tertinggi pada Bahasa Sunda ditunjukkan pada tabel 9. Kata "nuhun" memiliki nilai *Chi-Square* tertinggi, yaitu 85.78781016.

TABEL IX
SELEKSI FITUR TERBAIK BAHASA SUNDA

Ranking	Kata	Nilai Chi-Square
1	nuhun	85.78781016
2	alhamdulillah	70.01926738
3	sia	45.43209013
4	bungah	40.67118109
5	seuri	39.23831447
...	...	...
1496	smoga	1.850039782
1497	mengharukan	1.848770373
1498	silang	1.848224997

1499	ngabulakarkeun	1.848224997
1500	pilgub	1.848224997


E. Proses Klasifikasi

Proses klasifikasi dilakukan dengan data dibagi menjadi data latih dan data uji. Proses ini dilakukan dengan menggunakan perbandingan 80%:20% (parameter $\text{test_size}=0,2$) dan fungsi train_test_split dari library $\text{sklearn.model_selection}$. Dengan demikian, 4.000 data digunakan untuk pelatihan, sedangkan 1.000 data untuk pengujian. Model *Naive Bayes* dilatih menggunakan fungsi *MultinomialNB* dalam library *Scikit-learn*. Untuk uji parameter yang akan digunakan adalah dengan parameter $\alpha = 0.01$ dan fit_prior bernilai *True* dengan membandingkan dua kernel yaitu *linear* dan *rbf*. Sedangkan model SVM dibangun menggunakan library *Scikit-learn* dengan modul *SVC (Support Vector Classifier)* dan menggunakan *GridSearch*. Untuk uji parameter yang akan digunakan adalah parameter $\text{cost (C)} = [0.1, 10, 100]$ serta parameter $\text{gamma } (\gamma) = [0.5, 10, 100]$.

Label pada data uji diprediksi menggunakan model yang sudah dilatih, dan hasil prediksi dibandingkan dengan label sebenarnya. Jika label yang diprediksi sama dengan label sebenarnya, maka prediksi tersebut dianggap benar. Jika tidak sama, maka prediksi tersebut dianggap salah.

F. Evaluasi

Masing-masing model klasifikasi yang dihasilkan dievaluasi performanya dengan menggunakan parameter *accuracy*, *precision*, *recall*, dan *f1-score*. Untuk mendapatkan nilai-nilai tersebut, kelas aktual dibandingkan dengan kelas prediksi.



Gambar 3. Tabel Confusion Matrix

Gambar 3 menunjukkan confusion matrix berukuran 3 x 3 untuk model *Naive Bayes* dan *SVM* yang digunakan pada Bahasa Jawa dan Sunda, mencakup setiap kelas sentimen, yaitu positif, negatif, dan netral. Berdasarkan confusion matrix tersebut, terlihat bahwa dari 1.000 data yang diuji, model *Naive Bayes* untuk Bahasa Jawa

berhasil mengklasifikasikan dengan benar 304 data negatif, 51 data netral, dan 379 data positif. Sementara itu, model *Naive Bayes* untuk Bahasa Sunda mengklasifikasikan dengan benar 508 data negatif, 19 data netral, dan 239 data positif. Model *SVM* pada Bahasa Jawa mengklasifikasikan dengan benar sebanyak 304 data negatif, 99 data netral, dan 354 data positif. Model *SVM* pada Bahasa Sunda mengklasifikasikan dengan benar sebanyak 473 data negatif, 70 data netral, dan 258 data positif. Kemudian dengan menggunakan *confusion matrix*, dapat diketahui nilai *precision*, *recall*, *f1-score* dan *accuracy* nya yang ditunjukkan pada tabel 10.

TABEL X
HASIL PRECISION, RECALL, F1-SCORE, ACCURACY

	(Naive Bayes),(SVM)			
	Pesisi	Recall	F1-Score	Akurasi
Bahasa Jawa	(0.75),(0.75)	(0.73),(0.76)	(0.71),(0.75)	(73%),(76%)
Bahasa Sunda	(0.79),(0.80)	(0.77),(0.80)	(0.73),(0.80)	(77%),(80%)

G. Analisis Hasil

Analisis hasil dilakukan untuk mengevaluasi kinerja sistem dalam klasifikasi. *SVM* menunjukkan performa yang lebih baik daripada *Naive Bayes* dalam hal presisi, *recall*, *f1-score*, dan akurasi di kedua bahasa. Pada Bahasa Jawa, *Naive Bayes* memiliki presisi, *recall*, dan *f1-score* yang masing-masing adalah 0.75, 0.73, dan 0.71, dengan akurasi 73%. Sedangkan *SVM* lebih tinggi dengan presisi, *recall*, dan *f1-score* masing-masing sebesar 0.75, 0.76, dan 0.75, serta akurasi 76%. Sedangkan pada Bahasa Sunda, performa *Naive Bayes* meningkat dengan presisi 0,79, *recall* 0,77, *f1-score* 0,73 dan akurasi sebesar 77%. Sementara itu, *SVM* tetap lebih tinggi dengan presisi 0,80, *recall* 0,80, *f1-score* 0,80 dan akurasi 80%.

SVM lebih unggul dibandingkan *Naive Bayes* dalam klasifikasi sentimen, karena kemampuannya dalam menangani data berdimensi tinggi dan distribusi kelas yang tidak seimbang. Distribusi data yang tidak seimbang menyebabkan *Naive Bayes* mengalami kesalahan klasifikasi, terutama dalam membedakan sentimen netral dari positif atau negatif akibat asumsi independensi antar fitur. Sedangkan *SVM*, dengan margin maksimum yang lebih optimal, mampu memisahkan kelas dengan lebih baik dibandingkan *Naive Bayes* dan mengurangi tingkat kesalahan.

IV. KESIMPULAN

Pada penelitian ini penulis mencoba melakukan perbandingan kinerja antara algoritma *Support Vector Machine* dan *Naive Bayes* dalam mengenali sentimen positif, negatif, dan netral dalam kalimat Bahasa Jawa Ngoko dan Sunda, untuk memberikan rekomendasi mengenai algoritma yang paling sesuai pada klasifikasi sentimen ini. Dapat diambil kesimpulan bahwa algoritma *SVM* terbukti lebih unggul dibandingkan dengan *Naive Bayes* dalam klasifikasi sentimen teks berbahasa Jawa dan Sunda, dengan akurasi tertinggi yaitu di Bahasa Jawa 76% dan Bahasa Sunda 80%. *SVM* juga memberikan hasil yang lebih baik dalam hal *precision*, *recall*, dan *f1-score*. Dalam hal klasifikasi teks bahasa daerah Jawa dan Sunda,

model SVM dianggap sebagai pilihan terbaik karena menyediakan keseimbangan yang baik dan akurasi yang tinggi. Dengan akurasi terbaiknya, SVM dapat memberikan wawasan mengenai efektivitas algoritma berbasis pembelajaran mesin untuk klasifikasi sentimen dalam bahasa daerah, khususnya Bahasa Jawa dan Sunda. Penelitian ini dapat menjadi dasar bagi pengembangan model analisis sentimen untuk bahasa-bahasa daerah lainnya di Indonesia. Namun, penelitian ini masih memiliki keterbatasan, yaitu ketidakseimbangan distribusi kelas. Oleh karena itu, rekomendasi untuk penelitian mendatang dengan menambahkan penggunaan teknik *oversampling* atau *undersampling* untuk menangani ketidakseimbangan data, sehingga dapat membantu mengurangi bias prediksi dan model dapat belajar lebih baik terhadap seluruh kelas sentimen, tidak hanya mengandalkan kelas dengan jumlah data terbanyak. Penelitian ini diharapkan dapat menjadi dasar bagi pengembangan lebih lanjut dalam analisis opini publik dan pemahaman sentimen dalam bahasa daerah di Indonesia.

DAFTAR PUSTAKA

- [1] A. D. Wattimena, Analisis Sentimen Teks Bahasa Indonesia Pada Media Sosial Menggunakan Algoritma *Convolutional Neural Network* (Studi Kasus: *E-Commerce*) *Sentiment Analysis Indonesian Language in Social Media With Convolutional Neural Network (Case Study: E-Commerce)*. 2018.
- [2] A. R. Isnain, H. Sulistianti, B. Hurohman, A. Nurkholis, and Styawati, "JEPIN (Jurnal Edukasi dan Penelitian Informatika) Analisis Perbandingan Algoritma LSTM dan Naive Bayes untuk Analisis Sentimen," 2022.
- [3] T. S. Sabrila, V. R. Sari, and A. E. Minarno, "Analisis Sentimen Pada Tweet Tentang Penanganan Covid-19 Menggunakan Word Embedding Pada Algoritma Support Vector Machine Dan K-Nearest Neighbor," *Fountain Informatics J.*, vol. 6, no. 2, p. 69, Jul. 2021, doi: 10.21111/fij.v6i2.5536.
- [4] G. Nugroho, D. T. Murdiansyah, and K. M. Lhaksana, "Analisis Sentimen Pemilihan Presiden Amerika 2020 di Twitter Menggunakan Naïve Bayes dan Support Vector Machine," 2021.
- [5] A. J. Firdausi, W. Astuti, and Adiwijaya, "Perbandingan Algoritma Klasifikasi SVM dan Naive Bayes Dalam Analisis Sentimen Pembelajaran Daring di Masa Pandemi COVID-19 di Twitter," 2022. [Online]. Available: <https://t.co/uq2luzmnkh>
- [6] G. P. Permana, D. A. Nugraha, and H. Santoso, "Perbandingan Performa SVM dan Naïve Bayes Pada Analisis Sentimen Aplikasi Game Online," 2022.
- [7] B. Gunawan, H. S. Pratiwi, and E. E. Pratama, "Sistem Analisis Sentimen pada Ulasan Produk Menggunakan Metode Naive Bayes," *JEPIN (Jurnal Edukasi dan Penelit. Inform.)*, vol. 4, no. 2, pp. 17–29, 2018, [Online]. Available: www.femaledaily.com
- [8] S. Shevira, I. Made, A. D. Suarjaya, and P. Wira Buana, "Pengaruh Kombinasi dan Urutan Pre-Processing pada Tweets Bahasa Indonesia," 2022.
- [9] H. Tuhuteru and A. Iriani, "Analisis Sentimen Perusahaan Listrik Negara Cabang Ambon Menggunakan Metode Support Vector Machine dan Naive Bayes Classifier," *J. Inform. J. Pengemb. IT*, vol. 3, no. 3, pp. 394–401, Oct. 2018, doi: 10.30591/jpit.v3i3.977.
- [10] Y. Romadhoni and K. F. H. Holle, "Analisis Sentimen Terhadap PERMENDIKBUD No.30 pada Media Sosial Twitter Menggunakan Metode Naive Bayes dan LSTM," vol. 7, no. 2, 2022.
- [11] C. Chairunnisa, I. Ernawati, and M. M. Santoni, "Klasifikasi Sentimen Ulasan Pengguna Aplikasi PeduliLindungi di Google Play Menggunakan Algoritma Support Vector Machine dengan Seleksi Fitur Chi-Square Cindy," 2022.
- [12] N. D. Pratama, Y. A. Sari, and P. P. Adikara, "Analisis Sentimen Pada Review Konsumen Menggunakan Metode Naive Bayes Dengan Seleksi Fitur Chi Square Untuk Rekomendasi Lokasi Makanan Tradisional," 2018. [Online]. Available: <http://j-ptiik.ub.ac.id>
- [13] S. Mazya Permataning Tyas, R. Sarno, and B. Setya Rintyama, "Analisis Perbandingan Metode Klasifikasi Sentimen Berita Saham: Pendekatan Machine Learning, Deep Learning, Transfer Learning, dan Graf," 2024.
- [14] D. Darwis, N. Siskawati, and Z. Abidin, "Penerapan Algoritma Naive Bayes untuk Analisis Sentimen Review Data Twitter BMKG Nasional," *J. TEKNO KOMPAK*, vol. 15, no. 1, 2021.
- [15] A. Nisa, E. Darwiyanto, and I. Asror, "Analisis Sentimen Menggunakan Naive Bayes Classifier dengan Chi-Square Feature Selection Terhadap Penyedia Layanan Telekomunikasi," 2019.
- [16] M. Windarti and A. Suradi, "Perbandingan Kinerja 6 Algoritme Klasifikasi Data Mining untuk Prediksi Masa Studi Mahasiswa" 2019.